

Otimizador Estatístico de Portfólios

Aplicação baseada na Teoria Moderna do Portfólio de Markowitz

Streamlit

Python

Finanças Quantitativas

Simulação de Monte Carlo

O desafio da alocação de investimentos



Como distribuir capital entre diferentes ativos?


Como equilibrar risco e retorno?

Como identificar combinações eficientes de ativos?




Decisões puramente intuitivas frequentemente geram carteiras ineficientes e sub-otimizadas.


Objetivo da Aplicação



Stack Tecnológica e Arquitetura



Funcionamento e Lógica de Execução



Teoria Moderna do Portfólio (Markowitz)



Criador:

Harry Markowitz
(Prêmio Nobel).




Paradigma:

A diversificação
reduz o risco não
sistemático do
portfólio.



Retorno Esperado



Carteira Ótima

Ineficiente

Risco (Volatilidade)



Mecanismo:

Otimização
matemática da
relação Risco
(Volatilidade) vs.
Retorno Esperado.



Fronteira Eficiente:

O conjunto de carteiras
que oferece o maior
retorno esperado para
um nível de risco
estritamente definido.

Processamento Estatístico e Motor Vetorizado



Retornos

Baseados em retornos logarítmicos contínuos, anualizados (x 252 dias).



Risco Coletivo

Utilização da Matriz de Covariância para capturar a correlação cruzada entre os ativos.



Desempenho

Índice de Sharpe = (Retorno do Portfólio – Taxa Livre de Risco) / Volatilidade.

```
// Cálculo de retornos vetorizado
```



```
retornos_ln = np.log(  
    precos_df / precos_df.shift(1)  
)
```

```
// Álgebra Linear de Alta Performance em NumPy
```

```
retornos_portfolios = np.dot( pesos_matriz,  
    retornos_anuais )
```

```
variancias_portfolios =  
    np.einsum( 'ij,jk,ik->i', pesos, cov_matrix,  
    pesos)
```


Geração Vetorizada das Carteiras (Monte Carlo)



1. Mecânica

Milhares de matrizes de pesos são geradas de forma puramente aleatória.



2. Normalização

O algoritmo força a restrição orçamentária ajustando a soma dos pesos de cada carteira para exatamente 100%.



3. Avaliação

Para cada vetor simulado, o motor calcula simultaneamente o Retorno Esperado, a Volatilidade total e o respectivo Índice de Sharpe.

Painel de Configuração Flexível



Ativos

AAPL, MSFT, GOOG

Data Início



Data Fim



Capital Total (\$)

100000\$

Taxa Livre de Risco (TLR)

3.50%

03.50%

Número de Simulações

10,000

010,000

Executar Otimização Vetorizada 



Seleção de Ativos: Input de múltiplos tickers separados por vírgula.



Janela de Tempo: Controle preciso do período de backtest histórico.



Capital Disponível: Definição do valor base em \$ para a alocação final.



TLR Dinâmica: Captura automática da 10-Year Treasury Yield via API, com opção de ajuste manual.



Volume de Simulações: Slider controlando a profundidade do Monte Carlo, permitindo de 2.000 a 25.000 iterações.

Carteira Ótima Encontrada (Max Sharpe)

Retorno Esperado do Portfólio

24.50%



Risco Anualizado / Volatilidade

14.20%




Índice Sharpe Máximo

1.7253




A identificação exata da carteira ideal é extraída da matriz consolidada de simulações utilizando o método `idxmax()` do Pandas.

Mapeamento das Carteiras Simuladas




Distribuição Tática dos Recursos



Ativo	Peso (%)	Aporte Sugerido (\$)
MSFT	38.5%	\$ 3,850.00
AAPL	24.2%	\$ 2,420.00
GOOG	18.1%	\$ 1,810.00
NVDA	12.0%	\$ 1,200.00
SPY	7.2%	\$ 720.00

O aplicativo traduz os pesos ótimos definidos pela matemática vetorial multiplicando-os pelo capital total inserido, gerando uma ordem de aporte diretamente executável.

Evolução Simulada do Portfólio (Base 100)



O backtest simula um aporte inicial normalizado de \$100. Demonstra visualmente como a diversificação matemática amortece choques de volatilidade enquanto preserva o crescimento do capital em relação à exposição isolada.

Limitações Metodológicas do Modelo



Estatísticas e Dados

Retornos passados não garantem retornos futuros.

Forte sensibilidade metodológica à janela temporal escolhida no input.

Dependência da estabilidade e precisão dos dados extraídos do Yahoo Finance.



Premissas de Markowitz

Ignora fricções reais do mercado (custos de corretagem, impostos, spreads).

Não considera restrições bruscas de liquidez.

Assume estabilidade nas correlações históricas (vulnerável a eventos extremos e Cisnes Negros).



Engenharia de Simulação

Monte Carlo gera aproximações estocásticas, não uma solução analítica fechada.

O resultado marginal e a precisão da fronteira variam levemente a cada re-execução dependendo do número total de simulações.

Conclusão e Roadmap Futuro

Principais Entregas

- ✓ Aplicação interativa funcional e robusta de finanças quantitativas.
- ✓ Implementação performática, puramente vetorizada em NumPy, da clássica Teoria de Markowitz.
- ✓ Conversão direta de dados estatísticos brutos em inteligência financeira acionável e visual.

Roadmap de Engenharia

- ➔ Adição de otimizadores quadráticos formais (Scipy) para validar e expandir o Monte Carlo.
- ➔ Implementação de métricas modernas de risco de cauda (CVaR / Expected Shortfall).
- ➔ Módulos para restrições customizadas de alocação (ex: 'Máximo de 20% em um único ativo').
- ➔ Módulo de comparação contínua de desempenho contra Benchmarks oficiais (S&P 500 / IBOV).